Université du Québec à Chicoutimi

LIARA - Laboratoire sur l'Intelligence Ambiante pour la Reconnaissance d'Activité

Stage - Juin à Décembre 2026

Revue de littérature

Étudiant
BONNEAU Mathieu

Remis à
Julien MAITRE

7 juillet 2026

UQAC
Université du Québec
à Chicoutimi

Table des matières

1 Indoor Human Activity Recognition Using Multiple Dynamic Nonlinear Mapping Applied to 3-D LiDAR-Collected Data **3**
1.1 Résumé . . . 3
1.2 Data . . . 3
1.3 Data Collection . . . 4
1.4 Data processing . . . 5
1.5 Methodo . . . 5
1.6 Deep Learning . . . 7
1.7 Résultats . . . 8

2 Lidar-Based Human Activity Recognition Through Laplacian Spectral Analysis **11**
2.1 Résumé . . . 11
2.2 Data . . . 11
2.3 Data Collection . . . 12
2.4 Data processing . . . 12
2.5 Methodo . . . 13
2.6 Machine Learning . . . 14
2.7 Résultats . . . 14

3 LiDAR Point Cloud Feature Learning with One-Class SVM for Efficient Human Recognition in Indoor Environment **18**
3.1 Résumé . . . 18
3.2 Data & Data Collection . . . 18
3.3 Data processing . . . 19
3.4 Methodo . . . 20
3.5 Deep Learning . . . 21
3.6 Résultats . . . 21

Article I

Xiang Meng et al. « Indoor Human Activity Recognition Using Multiple Dynamic Nonlinear Mapping Applied to 3-D LiDAR-Collected Data ». In : *IEEE Internet of Things Journal* 12.11 (2025), p. 16797-16812. DOI : 10.1109/JIOT.2025.3533556

1 Indoor Human Activity Recognition Using Multiple Dynamic Nonlinear Mapping Applied to 3-D LiDAR-Collected Data

1.1 Résumé

Cet article propose une méthode de reconnaissance d'activités humaines en intérieur à partir d'images de profondeur collectées par LiDAR 3D. Les auteurs transforment les données LiDAR en images de profondeur, puis améliorent leur lisibilité grâce à une méthode de remapping non linéaire appelée MDNLM. Cette transformation met davantage en évidence les frontières du corps humain, ce qui permet à un modèle OpenPose réentraîné, appelé DepthPose, d'extraire plus précisément les squelettes. Ces squelettes sont ensuite utilisés par un réseau CNN+LSTM pour classifier les activités. L'approche montre que l'amélioration de la représentation intermédiaire des données de profondeur peut fortement améliorer la qualité de l'extraction du squelette et donc la reconnaissance d'activités.

1.2 Data

La nature des données Il s'agit d'un jeu de données propriétaire créé pour l'étude.

Les statistiques clés Le volume total est de 1128 séquences de 32 frames. 11 sujets ont été enregistrés. Des images RGB et de profondeurs sont capturées.

Les classes

TABLE II
DISTRIBUTION OF THE DATA COLLECTED WITH THE REALSENSE LIDAR CAMERA L515

Activities			Number of Samples
2-class	7-class	10-class	
Non-fall	walking	walking	294
	start sitting	start sitting	34
	keep sitting	keep sitting on a chair	286
		keep sitting on the floor	52
	standing up	standing up	30
	lying down	lying down	112
	squatting	squatting	100
		moving furniture	116
		wiping a desk	52
Fall	falling	falling	52

FIGURE 1 – Distribution des classes

1.3 Data Collection

L'environnement

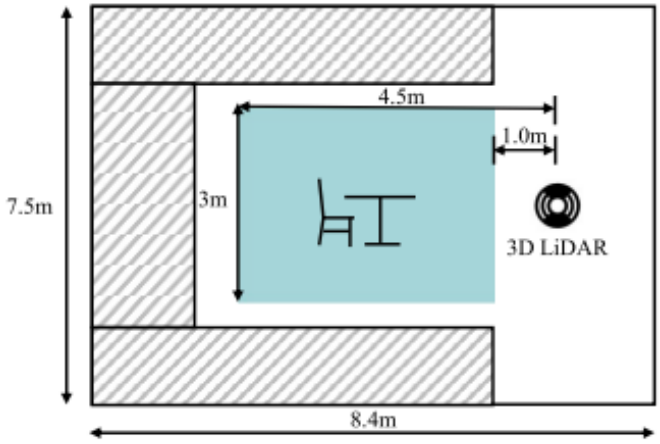


Fig. 2. Experiment room: Blue marks the area where the subjects perform the activities and gray marks obstacles that block the LiDAR signal.

FIGURE 2 – Salle d'expérimentation

La zone bleue est la zone d'activité du sujet. La zone grise représente les obstacles bloquant le signal du LiDAR. Le LiDAR est placé à 70cm de hauteur.

Le matériel

TABLE I
SPECIFICATIONS OF REALSENSE LIDAR CAMERA L515

LiDAR Model	Intel Realsense L515
Resolution	1024 × 768
VCSEL Wavelength	860 nm, Indoors
Depth Accuracy	5-14 mm
Working Distance	0.25-9 m
Depth Field of View	70° × 55° (±3°)
Frame Rate	30 FPS

FIGURE 3 – Matériel utilisé

Le protocole Chaque sujet réalise chaque activité au moins deux fois, de manière libre. Au total, 44 767 images. Chaque sample est segmenté à la main avec 32 images.

1.4 Data processing

Transfer learning pour réentraîner le modèle **OpenPose** afin d'obtenir les points clés du squelette sur les images de profondeurs.

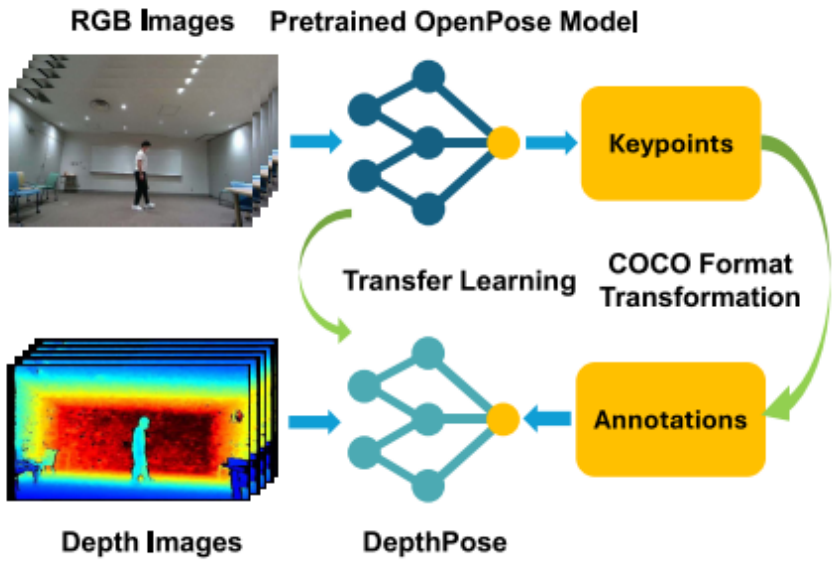


Fig. 3. Overview of DepthPose by transfer learning.

FIGURE 4 – Tranfer learning

Calibration Calibration et alignement des images RGB et profondeurs pour avoir la même résolution et vue.

Vérité terrain Extraction de 18 points clés du squelette en injectant l'image RGB dans OpenPose.

Annotation Les points sont convertis au format COCO car OpenPose s'est entraîné desssus.

Tranfer learning Avec les annotations au format COCO et les images profondeurs, OpenPose est réentraîné avec VGG19 comme backbone.

lr $= 2 \times 10^{-5}$; weight decay $= 5 \times 10^{-4}$ — step decay learning rate policy $= 0.333$ — Optimiseur MultiSGD — Perte Euclidienne — 200 époques max.

1.5 Methodo

Single Dynamic Nonlinear Mapping Block (SDNLM) identifie la position humaine et applique une transformation non-linéaire sur la carte de profondeur pour qu'il y

ait plus de couleurs sur le corps humain. Yolov5 permet d'avoir la bounding box et ainsi la position du centre du sujet. Une transformation presque sigmoïde est appliquée selon la formule $S(x) = \frac{1}{1+e^{-k(x-x_0)}}$. k permet d'ajuster la courbure de la fonction et se calcule avec une autre formule.

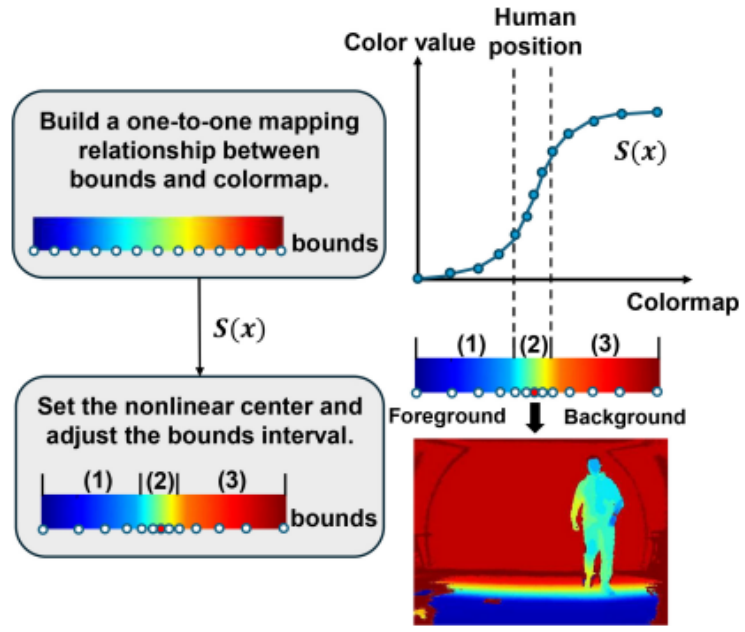


Fig. 6. Flowchart summarizing SDNLM block.

FIGURE 5 – SDNLM

Multiple Dynamic Nonlinear Mapping Block (MDNLM) L'objectif étant de s'adapter à toutes les morphologie, on cherche à avoir 3 SDNLM. Chacune sont obtenue à partir de 3 points clés : le haut, le centre, le bas. Le centre est obtenue avec Yolov5. Pour obtenir le haut on applique la méthode single sur le centre de l'humain puis OpenPose réentraîné pour obtenir les 18 points clés, notamment celui du cou. Si le joint du cou n'est pas détecté dans une frame, les auteurs réutilisent sa position issue de la frame précédente. Pour le bas on calcule simplement par symmétrie : $d_l = 2d_h - d_u$.
Chaque SDNLM Block est envoyé à l'OpenPose pour obtenir trois sets de squelette. Ils sont finalement fusionné. Si il y a des joints communs la moyenne est calculée. S'il n'est détecté nul part, il est codé comme absent.

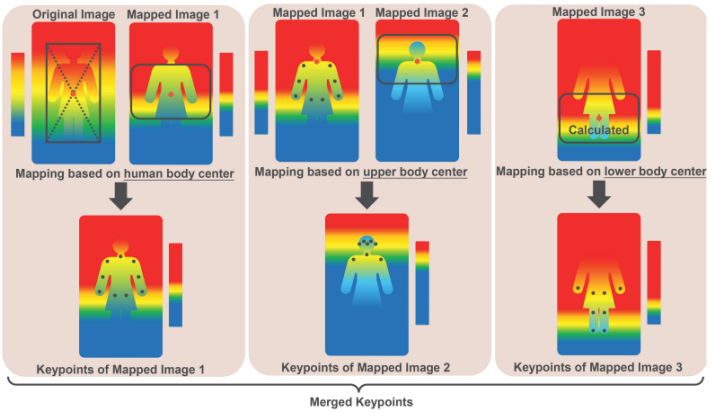


Fig. 7. Illustrative figure of MDNLM method.

FIGURE 6 – MDNLM

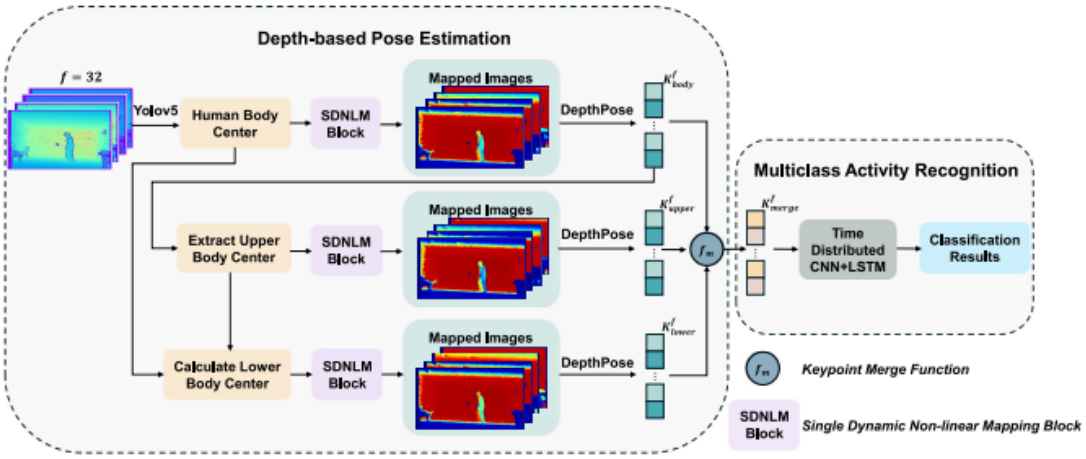


Fig. 1. Overall of our approach. Summarizing our two main tasks: depth-based pose estimation and multiclass activity recognition.

FIGURE 7 – Pipeline du projet

1.6 Deep Learning

L'architecture du réseau Avant le LSTM on extrait des features par une convolution 1D. Le réseau est terminé par deux couches entièrement connectées.

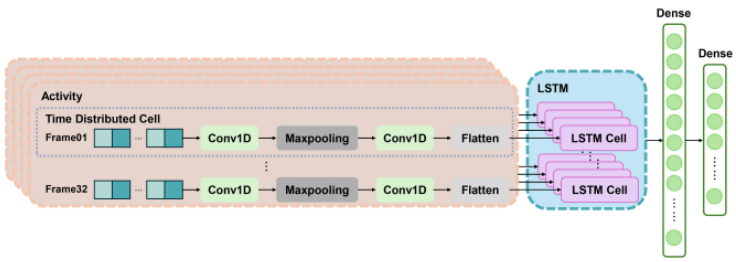


Fig. 8. Architecture of the neural network used for multiclass activity recognition.

FIGURE 8 – Architecture du modèle

Les hyperparamètres Optimiseur Adam (0.001) — CrossEntropy.

1.7 Résultats

Les métriques de performance Pour le squelette : percentage of correct keypoints (PCK). Pour la classification : accuracy, precision, recall, F1 score.

TABLE III
PCK VALUE OF POSE ESTIMATION

	Walking	Start Sitting	Keep Sitting on a Chair	Keep Sitting on the Floor	Standing Up	Lying Down	Squatting	Moving Furniture	Wiping a Desk	Falling	**Avg.**
RGB-based											
OpenPose [15] (RGB-dark)	5.0%	3.5%	4.7%	0.5%	0.4%	2.1%	6.0%	4.7%	3.4%	2.0%	3.2%
Depth-based											
OpenPose [15]	21.3%	16.0%	27.0%	16.3%	21.9%	12.0%	9.7%	17.1%	22.3%	7.7%	17.1%
KAPAO [14]	29.8%	33.0%	39.7%	30.4%	46.0%	15.1%	18.9%	23.4%	30.3%	12.4%	25.9%
DepthPose	43.8%	31.9%	39.2%	28.5%	41.8%	26.5%	30.3%	39.1%	45.8%	31.5%	35.8%
SDNLM [21]	64.1%	45.2%	54.7%	43.3%	53.0%	48.5%	45.3%	51.0%	65.3%	51.8%	52.2%
MDNLM	**90.3%**	**81.2%**	**89.0%**	**82.5%**	**87.7%**	**68.0%**	**76.0%**	**79.7%**	**95.1%**	**72.9%**	**82.2%**

FIGURE 9 – Résultats sur l'extraction du squelette

TABLE V
RATIO OF EXTRACTED MAIN SKELETON JOINTS OF POSE ESTIMATION

	RGB-based		**Depth-based**				
	OpenPose (RGB)	OpenPose (RGB-dark)	OpenPose	KAPAO	DepthPose	SDNLM	**MDNLM**
The Ratio of Main Joints	100.0% (Ground-truth)	5.8%	15.3%	49.8%	40.73%	74.1%	**92.0%**

FIGURE 10 – Comparaison PCK RGB/Profondeur dans un environement noir

TABLE VI
PERFORMANCE (ACCURACY, PRECISION, RECALL, AND F1 SCORE) OF MULTICLASS ACTIVITY RECOGNITION

	2-class				7-class				10-class			
	Acc.	Prec.	Rec.	F1	Acc.	Prec.	Rec.	F1	Acc.	Prec.	Rec.	F1
RGB-based												
OpenPose [15](RGB)	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%	94.7%	94.7%	95.0%	94.7%
OpenPose [15](RGB-dark)	95.9%	92.0%	95.9%	93.9%	40.0%	27.4%	40.0%	26.5%	32.7%	15.3%	32.7%	18.7%
Depth-based												
OpenPose [15]	96.8%	96.7%	96.7%	96.7%	72.0%	68.5%	72.0%	68.4%	54.9%	48.1%	54.9%	50.8%
KAPAO [14]	95.9%	92.0%	95.9%	93.9%	71.0%	61.0%	71.0%	65.5%	60.2%	51.0%	60.2%	53.9%
DepthPose	96.8%	96.7%	96.7%	96.7%	81.0%	81.0%	80.6%	80.4%	76.1%	76.7%	76.1%	75.4%
SDNLM [21]	99.2%	99.2%	99.2%	99.1%	90.0%	90.0%	91.5%	88.9%	82.3%	82.3%	83.3%	82.0%
MDNLM	**100.0%**	**100.0%**	**100.0%**	**100.0%**	**99.0%**	**99.3%**	**99.0%**	**99.0%**	**94.7%**	**94.6%**	**94.7%**	**94.5%**

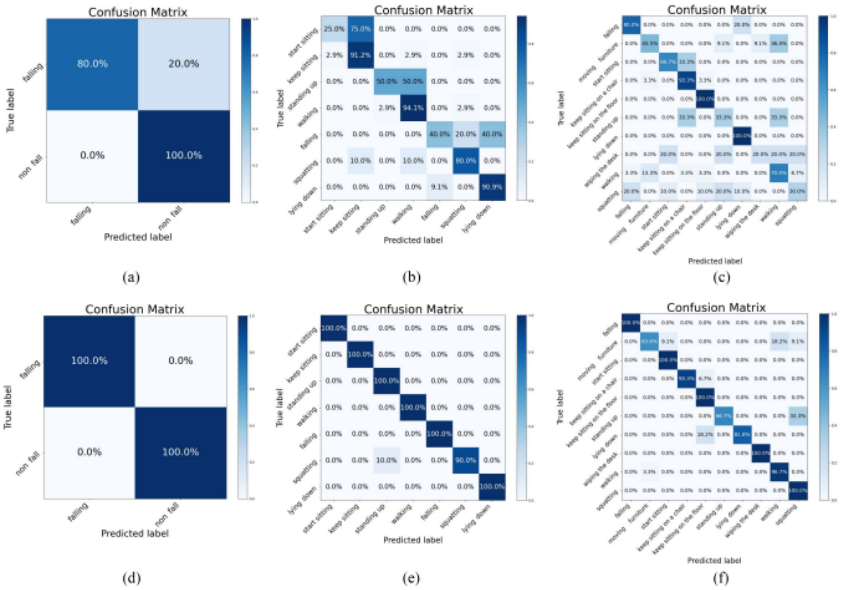


FIGURE 11 – Résultats de la classification

Les comparaisons —

TABLE VII
PERFORMANCE COMPARISON WITH STATE-OF-THE-ART NETWORKS

	2-class				7-class				10-class			
	Acc.	Prec.	Rec.	F1	Acc.	Prec.	Rec.	F1	Acc.	Prec.	Rec.	F1
LSTM [47]	99.2%	99.3%	99.2%	99.2%	97.0%	97.7%	97.0%	96.9%	86.7%	86.9%	86.7%	86.5%
BiLSTM [48]	99.2%	99.3%	99.2%	99.2%	97.0%	97.3%	97.0%	96.8%	88.5%	88.9%	88.5%	87.7%
TCN [49]	100.0%	100.0%	100.0%	100.0%	91.0%	88.6%	91.0%	89.3%	87.6%	87.3%	87.6%	86.7%
Ours	**100.0%**	**100.0%**	**100.0%**	**100.0%**	**99.0%**	**99.3%**	**99.0%**	**99.0%**	**94.7%**	**94.6%**	**94.7%**	**94.5%**

FIGURE 12 – Comparaison avec l'état de l'art

Limites SDNLM doit être run pour chaque personne dans un environnement avec du monde. Occlusions : la méthode ne reconstruit pas les parties du corps manquantes ou cachées. Split pas détaillé !

Pistes Multimodal avec des images thermiques.

Article II

Sasan Sharifipour et al. « Lidar-Based Human Activity Recognition Through Laplacian Spectral Analysis ». In : *ICASSP 2026 - 2026 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2026, p. 3226-3230.
DOI : 10.1109/ICASSP55912.2026.11462769

2 Lidar-Based Human Activity Recognition Through Laplacian Spectral Analysis

2.1 Résumé

Cet article propose une approche différente de la reconnaissance d'activités humaines à partir de LiDAR : au lieu d'extraire un squelette ou d'entraîner directement un réseau profond sur les nuages de points, les auteurs représentent la segmentation du nuage de points de la personne sous forme de graphe. Les points du nuage deviennent les sommets du graphe, et des arêtes sont créées entre les points proches spatialement. La structure géométrique de ce graphe est ensuite décrite à l'aide du spectre de sa matrice laplacienne, c'est-à-dire ses valeurs propres et des statistiques associées aux vecteurs propres. Ces descripteurs capturent la forme globale et locale de la posture humaine, puis sont agrégés temporellement sur des fenêtres glissantes pour représenter le mouvement. La classification est ensuite réalisée avec des modèles classiques comme SVM, Random Forest ou MLP. L'intérêt principal de cette méthode est de proposer sans dépendre d'une estimation de squelette potentiellement bruitée.

2.2 Data

La nature des données Il s'agit d'un jeu de données public. MM-Fi dataset.

Les statistiques clés Le volume total est de 1080 séquences, 320.76k frames sur 5 capteurs : RGB, profondeur, LiDAR, mmWave, WiFi. Cette étude utilise uniquement les données LiDAR et les annotations d'action. 40 sujets.

Scale and Modalities

Dataset	Modalities					Annotations					# Subj	# Act	# Seq	# Frame
	RGB	Depth	LiDAR	mmWave	WiFi	Action	3DPOS	2DKP	3DKP	3DDP				
COCO [17]	✓	-	-	-	-	-	-	✓	-	-	-	-	-	104k
MPII [4]	✓	-	-	-	-	✓	-	✓	-	-	-	410	24k	25k
MPI-INF-3DHP [18]	✓	-	-	-	-	-	-	✓	✓	-	8	8	16	1.3M
CMU Panoptic [14]	✓	✓	-	-	-	-	-	✓	✓	-	8	5	65	154M
Human3.6M [12]	✓	✓	-	-	-	✓	-	✓	✓	-	11	17	839	3.6M
NTU RGB+D [30]	✓	✓	-	-	-	✓	-	✓	✓	-	40	60	56k	4M
3DPW [33]	✓	-	-	-	-	-	-	✓	✓	-	7	-	60	51k
MPI08 [24]	✓	-	-	-	-	-	-	-	✓	-	4	24	24	14k
TNT15 [34]	✓	-	-	-	-	✓	-	-	✓	-	1	5	-	14k
MoVi [10]	✓	-	-	-	-	✓	-	✓	✓	-	90	21	1044	712k
LiDARCap [16] *	✓	-	✓	-	-	✓	-	-	✓	-	13	20	-	184k
Waymo [45] *	✓	✓	✓	-	-	-	-	✓	✓	-	13	-	1950	184k
HuMMan [7]	✓	✓	✓	-	-	✓	-	✓	✓	-	1000	500	400k	60M
RF-Pose [43] *	✓	-	-	✓	-	✓	-	✓	-	-	100	1	-	-
RF-Pose3D [44] *	✓	-	-	✓	-	✓	-	✓	✓	-	>5	5	-	-
mmPose [29] *	-	-	-	✓	-	✓	-	-	✓	-	2	4	-	40k
mmMesh [36] *	✓	-	-	✓	-	✓	-	-	✓	-	20	8	-	3k
MARS [2]	-	-	-	✓	-	✓	-	-	✓	-	4	10	80	40k
mRI [1]	✓	✓	-	✓	-	✓	-	✓	✓	-	20	12	300	160k
AHA-3D [5]	✓	-	-	-	-	✓	-	-	✓	-	21	4	79	170k
HPTE [6]	✓	✓	-	-	-	✓	-	-	✓	-	5	8	240	100k
WiPose [13] *	✓	-	-	-	✓	✓	-	-	✓	-	10	16	-	96k
GoPose [27] *	✓	-	-	-	✓	✓	-	-	✓	-	10	>9	-	676.2k
MM-Fi	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	40	27	1080	320.76k

FIGURE 13 – Dataset MM-Fi

Les classes 27 classes — 14 activités quotidiennes — 13 exercices de réhabiliation

Activités quotidiennes (a) chest expanding horizontally, (b) chest expanding vertically, (c) left side twist, (d) right side twist, (e) raising left arm, (f) raising right arm, (g) waving left arm, (h) waving right arm, (i) picking up things, (j) throwing toward left side, (k) throwing toward right side, (l) kicking toward left direction using right leg, (m) kicking toward right direction using left leg, (n) bowing

Exercices de réhabilitation (a) stretching and relaxing in free form, (b) mark time, (c) left upper limb extension, (d) right upper limb extension, (e) left front lunge, (f) right front lunge, (g) both upper limbs extension, (h) squat, (i) left side lunge, (j) right side lunge, (k) left limbs extension, (l) right limbs extension, (m) jumping up

2.3 Data Collection

L'environnement Deux salles de $8.5m \times 7.8m$. Quatre environnements différents avec 10 sujets par environnement.

Le matériel Intel RealSense D435 camera, the Texas Instrument IWR6843 60-64GHz mmWave, radar, the Ouster OS1 32-line LiDAR, and a pair of TP-Link N750 WiFi APs.

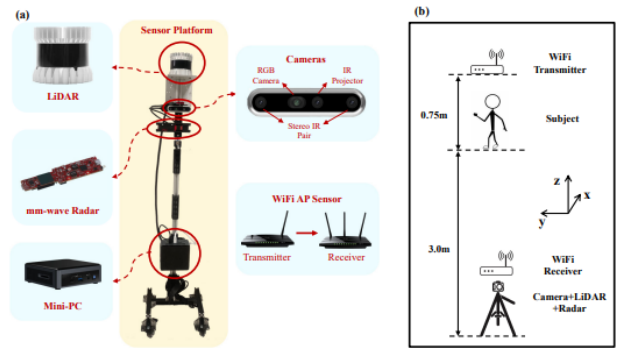


Figure 1: Overview of the experimental setup for data collection. (a) shows the customized sensor platform with one mini-PC for data synchronization and four sensor devices including Ouster OS1 32-channel LiDAR, TI IWR6843 mmWave radar, Intel Realsense D435 stereo depth camera, and TP-Link N750 WiFi APs. (b) shows the layout of data collection where all subjects are positioned 3.0m away from the platform. The WiFi transmitter is placed 0.75m away from the subject.

FIGURE 14 – Vue d'ensemble pour la collection de données

Le protocole 30s par classe. Les 14 activités quotidiennes sont réalisées librement dans l'espace. Les 13 exercices de réhabilitation sont fixés dans l'espace.

2.4 Data processing

3D person Detection Détection d'une seule personne 3D avec une architecture PV-RCNN (PointVoxelRegion-based Convolutional Neural Network) à l'aide du framework OpenPCDet. Plusieurs étages : Voxel Feature Encoder (VFE) avec MeanVFE (grille du cubes) — backbone 3D VoxelBackBone8x (sparse processing, ignore les cubes vides) —

backbone 2D avec BaseBEVBackBone (vue d'oiseau) pour passer en 2D.

Training data Le dataset ne contenant pas de bounding box 3D, des données d'entraînement ont été générées à partir des estimations des poses 3D, du squelette en quelque sorte afin de pouvoir entraîner le PV-RCNN.

Segmentation Cette bouding box permet de segmenter les points de la scène pour ne garder que ceux de la personne.

2.5 Methodo

Nuage de point vers une représentation en graphe Graphe non orienté. Arête créée si la distance euclidienne entre deux point est strictement inférieur à un rayon r. C'est un hyperparamètre.

Cadrants Pour créer plus de features discriminantes, des graphes supplémentaires sont créés en partitionant le nuage de points en 4 cadrants (médiane horizontale et verticale). Les valeurs propres décrivent la connectivité et la géométrie globale du graphe. Les vecteurs propres décrivent des modes spatiaux sur le nuage de points. Le spectre est invariant à la permutation des points.

Analyse spectrale laplacienne Matrice d'adjacence A et matrice diagonale de degrés D on obtient la matrice Laplacienne L = D - A. Les valeurs et vecteurs propres vont servir à établir les features.

Features valeurs propres 2 méthodes sont comparées pour la créations des features à partir des valeurs propres. 1ère *Statistical Summary* : statistiques (mean, standard deviation, median, 25th/75th percentiles, max). 2ème *Direct Selection* : Garder les K_{val} premières valeurs.

Features vecteurs propres On concatène les statistiques des K_{vec} vecteurs propores (mean, standard deviation, max,min, kurtosis, Shannon entropy of its squared components, and the range of its absolute values).

Aggrégation en fenêtre temporelle Comparaison de deux méthodes d'aggrégation. 1ère *Temporal Statistics* : statistiques sur chaque feature dans la séquence temporelle (mean, standard deviation, range, median, interquartile range, skewness, kurtosis). 2ème *Concatenation* : concaténation en un seul grand vecteur.

Vecteur de features final Total de 4 stratégies comparées. Les features des vecteurs propres sont concaténés à ceux d'une stratégie explorée des valeurs propres.

Classification MM-Fi cross_scene_split permet à la fois que les sujets et les salles ne soient pas vus lors de l'entraînement. Les features sont standadisées avec *StandardScaler*.

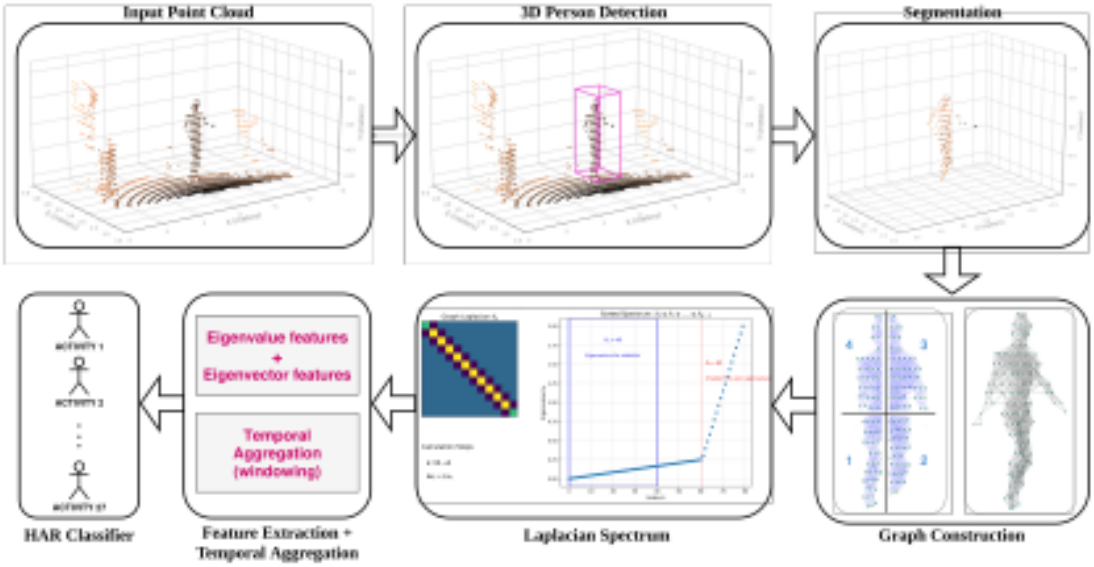


Fig. 2. An overview of the proposed Laplacian-based HAR pipeline. The process starts with a raw input LiDAR frame.

FIGURE 15 – Pipeline du projet

2.6 Machine Learning

L'architecture du réseau 3 modèles explorés : Support Vector Machine (SVM), Random Forest (RF), Multi-layer Perceptron (MLP).

Les hyperparamètres $r = 0.20m$. Aggrégation temporelle testées sur $w \in \{2, 4, 6\}s$ avec un stride de 0.5s. À 10Hz cela correspond à $\{20, 40, 60\}$ images par aggrégation temporelle et un stride de 5 frames. $K_{val} = 60, K_{vec} = 40$.

2.7 Résultats

Les métriques de performance window-level accuracy ; Top-1 accuracy ; Top-5 accuracy

Meilleure stratégie La stratégie qui sur-performe toutes les autres et celle qui prend les valeurs propres brutes *Direct Selection* puis qui utilise les statistiques sur les frames de l'aggrégation temporelle *Temporal Statistics*. De même, les meilleurs résultats SVM selon les parties du corps sont obtenus avec le graphe du corps entier combiné avec les 4 cadrants.

Table 1. Window-level accuracy (%) under the subject split for four strategies on 13 and 27 activities with $w \in \{2, 4, 6\}$ s. Values are mean ± bootstrap STD over test windows (stride 0.5 s). Classifier: Random Forest. Best per strategy and w in bold.

Strategy	13 activities			27 activities		
	w=2	w=4	w=6	w=2	w=4	w=6
A	76.89 ± 0.80	81.45 ± 0.80	82.96 ± 0.91	73.10 ± 0.60	78.06 ± 0.62	81.91 ± 0.64
A (+ f_t^{vec})	84.36 ± 0.71	87.42 ± 0.71	88.05 ± 0.81	74.51 ± 0.57	78.13 ± 0.61	79.91 ± 0.66
B ($K_{\text{val}} = 60$)	82.71 ± 0.71	88.96 ± 0.66	89.29 ± 0.75	75.86 ± 0.58	83.14 ± 0.55	83.70 ± 0.65
B ($K_{\text{val}} = 60 + f_t^{\text{vec}}$)	**88.64 ± 0.59**	**91.81 ± 0.61**	**90.41 ± 0.72**	**81.31 ± 0.53**	**83.59 ± 0.57**	**84.47 ± 0.61**
C	65.82 ± 0.87	66.33 ± 0.97	66.09 ± 1.15	52.89 ± 0.66	52.96 ± 0.73	53.11 ± 0.83
C (+ f_t^{vec})	80.99 ± 0.75	84.48 ± 0.77	84.08 ± 0.86	66.60 ± 0.65	69.83 ± 0.69	72.54 ± 0.73
D ($K_{\text{val}} = 60$)	74.62 ± 0.85	73.89 ± 0.96	70.18 ± 1.08	66.86 ± 0.64	66.97 ± 0.73	66.07 ± 0.80
D ($K_{\text{val}} = 60 + f_t^{\text{vec}}$)	83.74 ± 0.71	86.33 ± 0.72	80.47 ± 0.94	69.03 ± 0.62	73.46 ± 0.63	74.23 ± 0.69

FIGURE 16 – Résultats obtenus

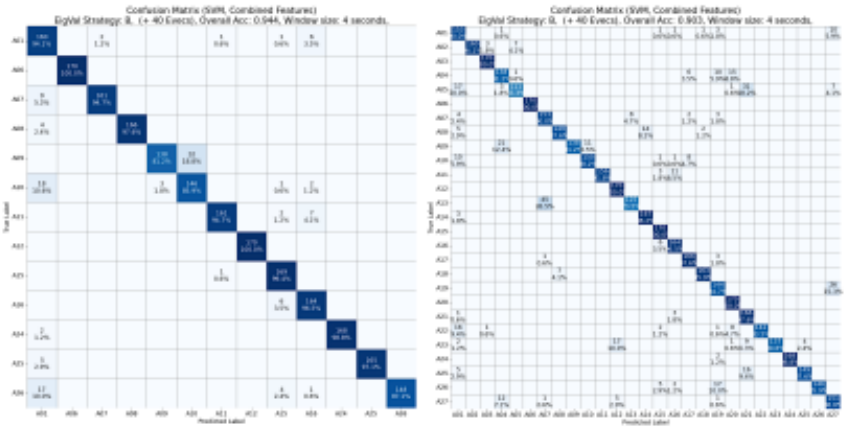


Fig. 3. Confusion matrices for 13 and 27 activities with the best setting (SVM, $r = 0.15$ m, standardized features, whole body + quadrants).

FIGURE 17 – Matrices de confusion

Table 2. Window–level recognition accuracy (%) under the subject split for different spatial partitions and classifiers.

Combination	13 activities			27 activities		
	RF	SVM	MLP	RF	SVM	MLP
Whole body only (part=0)	54.98	61.04	59.05	41.48	53.14	51.68
Four quadrants only (parts 1–4)	88.14	92.81	92.67	79.78	87.71	78.91
Three quadrants only (parts 3–5)	86.02	90.05	91.95	82.72	86.82	83.42
Whole body + four quadrants (0 + 1–4)	91.81	**94.39**	93.57	83.88	**90.33**	84.38
Whole body + upper quadrants (0 + 3,4)	87.83	92.26	92.76	82.48	87.58	84.90
Only legs (part=5)	51.45	60.81	61.40	42.31	50.26	49.83

Notes: Vector features extracted using Strategy B + Eigenvector features. Window length = 4 seconds. PCA=True (n_components=1500)

FIGURE 18 – Résultats sur le choix des graphes

Table 3. Window-level accuracy (%) for different radii and connectivity indicators ($\bar{d}$, $\bar{c}$) averaged over 130,680 frames.

r (m)	w=2	w=4	w=6	$\bar{d}$	$\bar{c}$
0.10	89.05	89.50	89.59	7.1704	3.3714
0.15	93.22	94.39	94.85	13.8681	1.6490
0.20	95.27	95.88	95.68	25.2315	1.4135
0.30	90.11	92.45	91.77	49.5356	1.3419

FIGURE 19 – Résultats sur le choix du rayon

Table 4. Top-1 and Top-5 accuracy (%) on MM-Fi LiDAR for 27 activities.

Method	**Protocol (Train/Test Subjects)**	**Top 1 (%)**	**Top 5 (%)**
AGCN [16]	Env. E04 (7/3)	54.44	91.03
CTRGCN [17]	Env. E04 (7/3)	35.97	74.12
Ours (SVM)	Env. E04 (7/3)	**81.26**	**96.66**
Ours (SVM)	Env. E01-E03 (30) / E04 (10)	**90.33**	**97.82**

FIGURE 20 – Comparaison avec le sota

Limites Dimension features par partie du corps grand : 4400. Le rayon r est fixe. C'est fragile si la densité du nuage de point varie.

Pistes construction de graphe adaptatif (including distance-weighted Laplacians). feature selection, compact projections, or learned embeddings.

Article III

Hadil Eltaif, Charles Gouin-Vallerand et Yacine Yaddaden. « LiDAR Point Cloud Feature Learning with One-Class SVM for Efficient Human Recognition in Indoor Environment ». In : *2026 22nd International Conference on Intelligent Environments (IE)*. 2026, p. 1-8. DOI : 10.1109/IE69249.2026.11539050

3 LiDAR Point Cloud Feature Learning with One-Class SVM for Efficient Human Recognition in Indoor Environment

3.1 Résumé

Cet article ne traite pas directement de reconnaissance d'activités, mais de détection de personnes en environnement intérieur à partir de nuages de points LiDAR. La méthode combine un extracteur de features profondes, entraîné sur le dataset L-CAS avec des architectures comme PointNet et PointNet++, puis un classifieur One-Class SVM chargé de décider si un cluster correspond à une personne ou non. L'extracteur profond apprend une représentation géométrique générale des clusters LiDAR, tandis que le One-Class SVM apprend uniquement la distribution des exemples de personnes. Cette stratégie permet de réduire le besoin d'exemples négatifs annotés, ce qui est pertinent en environnement intérieur où les objets non humains sont très variés. L'article montre également que le transfert direct entre datasets et capteurs provoque une chute de performance, mais qu'un réentraînement léger du One-Class SVM sur les données du nouvel environnement permet de restaurer de bons résultats sans réentraîner l'ensemble du modèle profond.

3.2 Data & Data Collection

La nature des données Il s'agit de deux jeux de données publics et d'un jeu de données créé en laboratoire. L-CAS et SZTAKI-LGA.

Les statistiques clés

L-CAS utilisé pour entraîner les extracteurs de features profonds en classification supervisée.

TABLE I
L-CAS 3D Point Cloud People Dataset: Key Statistics

Property	Value
Acquisition Site	University of Lincoln (UK)
Sensor	Velodyne VLP-16
Total Frames	28,002
Annotated Frames	5,492
Labeled Instances	9,122 (6068 single-person, 3,054 group of people)
Classes	Pedestrian, Group of people

Figure 21 – Statistiques clés de L-CAS

SZTAKI utilisé pour l'évaluation one-class et l'entraînement du OC-SVM sur des embeddings de personnes. LiDAR Velodyne HDL-32E

TABLE II
SZTAKI-LGA Activity Recognition Dataset: Key Statistics

Activity	Number of PCD Samples
Bend to Ground	1,018
Check Watch	552
Phone Call	684
Wave	731
Two-Handed Wave	431
Total (original)	**3,416**
Total (after augmentation)	**4,343**
Increase (%)	$\approx 30\%$

Figure 22 – Statistiques clés de SZTAKI

Laboratoire 4 participants en conditions d'habitat réelles. Utilisé pour valider la faisabilité pratique dans un environnement réel avec un autre capteur LiDAR

TABLE III
Laboratory Dataset: Key Statistics

Property	Value
Acquisition Site	Indoor laboratory environment (Domus Lab)
Sensor	Velodyne VLP-32C
Total Samples	1,790
Participants	4 different persons
Classes	Person

Figure 23 – Statistiques clés des données en laboratoire

3.3 Data processing

Point-Cloud Normalization Chaque cluster est translaté vers son centroïde et mis à l'échelle d'une sphère unitaire. Permet d'avoir un cadre de référence pour les clusters.

Fixed-Size Resampling La taille des clusters varie, elle est fixée par une taille N. Si le clusters à plus de N points, une sous-représentation est utilisée avec **Farthest Point Sampling (FPS)**. Sinon, on utilise du sur-échantillonage progessif.

Data Augmentation Uniquement sur SZTAKI. Seulement 3,416 samples. Le cluster est coupé en partie haute et partie basse puis une petite rotation est appliquée.

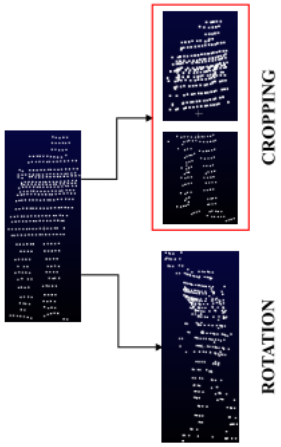


Fig. 2. Illustration of SZTAKI-LGA data augmentation. (**Top**) Body segmentation into upper and lower parts. (**Bottom**) Discrete yaw rotations to simulate viewpoint variations.

FIGURE 24 – Illustration de l'augmentation de données

3.4 Methodo

Phase hors-ligne Extraction des features pour discriminer les clusters. Ces features sont utilisées pour entraîner le SVM une classe ensuite. Quatre variantes d'extracteurs de features sont entraînés sur L-CAS : PointNet, PointNet++ SSG, PointNet++ MSG, PointNet avec de l'auto-attention. Entraînement sur trois classes *pedestrian, group,* et *non-person.*. Supervisé. N testé sur {256,512,1024}. Après convergence, la couche de clasification est supprimée et le reste est gelé. Le SVM est entraîné en prenant en entrée les features du modèle gelé.

Phase en ligne Détection des objets dynamiques par soustraction d'arrière plan en comparant chaque nouvelle image avec **fast KD-Tree search**. Les points manquants à la référence sont considérés comme dynamiques puis regroupés en cluster avec le clustering euclidien. Pour chaque cluster le pipeline effectue un pre-processing (normalisation, taille fixée d'échantillon), l'extraction des features en utilisant l'encodeur gelé suite à la phase hors-ligne, classification avec le SVM entraîné en mode hors-ligne.

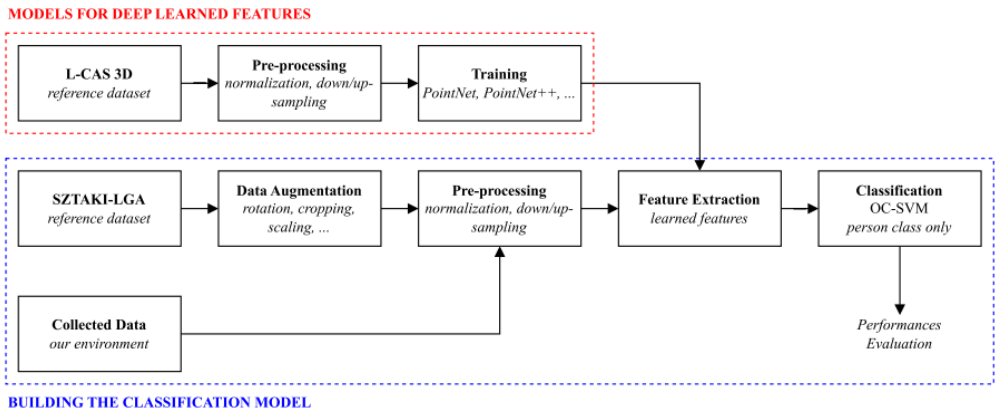


Fig. 1. Proposed LiDAR-based person detection framework, composed of an **offline phase** for feature learning and model training, and an **online phase** fo classification on our laboratory LiDAR streams.

FIGURE 25 – Pipeline du projet

3.5 Deep Learning

L'architecture du réseau d'extraction des features PointNet, PointNet++ SSG, PointNet++ MSG,, PointNet avec de l'auto-attention.

Classifieur One-class SVM Fonction de décision $f(x) = sign(< w, \phi(x) > +b)$. $\phi(x)$ projette les embeddings dans un espace noyau, w définit l'hyperplan, b le biais, et ν contrôle la proportion maximale d'outliers tolérés pendant l'entraînement. Paramètres obtenus en résolvant

$$\min_{\mathbf{w},\xi,\rho} \frac{1}{2}\|\mathbf{w}\|^2 + \frac{1}{\nu N}\sum_{i=1}^{N}\xi_i - \rho,$$

3.6 Résultats

Protocole

— Classification multiclasses sur L-CAS (PointNet) pour pouvoir comparer les résultats aux méthodes existantes et s'assurer de la qualité des features. Split 70/15/15. Classes : person, group, and non-person objects. 2000 échantillons (chair, table, sofa and background elements) de S3DIS sont ajoutés pour la classe non-person. Ces échantillons sont réutilisés pour le SVM.

— Classification binaire sur SZTAKI-LGA (SVM). Split 70% des inliers pour l'entraînement. Les 30% restants sont mélangés avec les outliers. Ce mélange est divisé en deux pour validation et test.

— Validation sur les données laboratoire. Split identique mais 60% inliers, validation et test 20% et 20%.

Métriques Accuracy, Precision, Recall, F1-score, and confusion matrices.

Meilleure stratégie

— L-CAS : PointNet++ MSG N=256

— SZTAKI ; PointNet++ SSG et MSG N=1024

Réentraînement du SVM Lorsque le SVM entraîné sur SZTAKI est testé en ligne dans le laboratoire, les résultats chuttent. Amélioration des résultats lorsque le SVM est réentraîné sur les données du laboratoire. Les embeddings profonds sont transférables, mais le classifieur one-class reste sensible au changement de capteur et d'environnement.

Pistes Tracking Attribution d'ID et estimation des trajectoires.

Bilan

Point de recul

La reconnaissance d'activité humaine se décompose deux parties. La première consiste à détecter l'humain. La deuxième à classifier son action.

Bien que les datasets actuels possèdent des données synchronisées provenant de plusieurs capteurs (e.g MM-Fi), les actions restent toutefois simples et limitées.

La détection de l'humain est réalisée à partir de grosses architectures telles que Yolov5, PV-RCNN ou PointNet+SVM. Une architecture à tester serait RF-DETR.

La classification de l'action peut être réalisée à partir de SVM comme d'une architecture plus complexe CNN+LSTM.

Aucun article utilisant deux LiDAR n'a été trouvé. Le principale avantage serait d'avoir un système plus robuste pour la détection de la personne, notamment contre l'occlusion. Par exemple, lorsqu'une personne est derrière une chaise, une table, un objet ou simplement de profil, la capture complète du nuage de points de la personne devient plus difficile avec un seul LiDAR. Or, un deuxième LiDAR permettrait de surmonter ce défi en capturant davantage d'informations. Cela impliquerait de calibrer les LiDAR (voir Hyunsuk Lee et Woojin Chung. « Extrinsic Calibration of Multiple 3D LiDAR Sensors by the Use of Planar Objects ». In : *Sensors* 22.19 (2022). ISSN : 1424-8220. DOI : 10.3390/s22197234. URL : https://www.mdpi.com/1424-8220/22/19/7234).